Linear model in WDE

In [1]:
```
#WDE dataset
WDE_path="C:/Users/aliba/OneDrive/Desktop/UNIVERSITA/TESI/DATASET/WalkingDistanceEstimation-master/dataset/"
classi=['armhand', 'pocket', 'calling', 'swing', 'handheld']
n_elem=500
n_left=50

import numpy as np
import matplotlib.pyplot as plt
import matplotlib.pyplot as plt
import pandas as pd

#model
from sklearn.model_selection import KFold
from sklearn.model_selection import train_test_split, GridSearchCV

#regression
from sklearn.model_selection import KFold
from sklearn import linear_model
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.preprocessing import StandardScaler
from sklearn.feature_selection import SelectKBest, f_regression
from sklearn.pipeline import Pipeline
from sklearn.metrics import make_scorer, r2_score


#visualization
from yellowbrick.regressor import PredictionError
from yellowbrick.regressor import ResidualsPlot
from yellowbrick.features import rank1d, rank2d
from yellowbrick.model_selection import FeatureImportances
from yellowbrick.model_selection import LearningCurve



from ipynb.fs.full.functioncollection import trueeqWDE,error_rate, importWDE, filtWDE, f_ext_WDE,makeeqWDE,full
```

Import all WDE

In [2]:
```
DATASET, stop_list =importWDE()
```

```
PDR_Raw_2019-03-20-09-10-12 {'armhand': 0, 'pocket': 0, 'calling': 0, 'swing': 0, 'handheld': 288}
Outliers eliminati       {'armhand': 0, 'pocket': 0, 'calling': 0, 'swing': 0, 'handheld': 12}

PDR_Raw_2019-03-20-09-21-02 {'armhand': 0, 'pocket': 0, 'calling': 284, 'swing': 0, 'handheld': 0}
Outliers eliminati       {'armhand': 0, 'pocket': 0, 'calling': 15, 'swing': 0, 'handheld': 0}

PDR_Raw_2019-03-20-09-29-55 {'armhand': 0, 'pocket': 0, 'calling': 34, 'swing': 0, 'handheld': 45}
Outliers eliminati       {'armhand': 0, 'pocket': 0, 'calling': 3, 'swing': 0, 'handheld': 1}

PDR_Raw_2019-03-21-08-32-39 {'armhand': 196, 'pocket': 0, 'calling': 0, 'swing': 0, 'handheld': 0}
Outliers eliminati       {'armhand': 26, 'pocket': 0, 'calling': 0, 'swing': 0, 'handheld': 0}

PDR_Raw_2019-03-21-09-07-51 {'armhand': 527, 'pocket': 0, 'calling': 0, 'swing': 0, 'handheld': 0}
Outliers eliminati       {'armhand': 203, 'pocket': 0, 'calling': 0, 'swing': 0, 'handheld': 0}

PDR_Raw_2019-03-21-11-57-56 {'armhand': 0, 'pocket': 0, 'calling': 0, 'swing': 197, 'handheld': 0}
Outliers eliminati       {'armhand': 0, 'pocket': 0, 'calling': 0, 'swing': 151, 'handheld': 0}

PDR_Raw_2019-03-24-11-12-21 {'armhand': 0, 'pocket': 142, 'calling': 0, 'swing': 139, 'handheld': 0}
Outliers eliminati       {'armhand': 0, 'pocket': 8, 'calling': 0, 'swing': 10, 'handheld': 0}

PDR_Raw_2019-03-28-11-50-11 {'armhand': 0, 'pocket': 0, 'calling': 275, 'swing': 429, 'handheld': 425}
Outliers eliminati       {'armhand': 0, 'pocket': 0, 'calling': 16, 'swing': 42, 'handheld': 121}

PDR_Raw_2019-03-29-07-37-22 {'armhand': 0, 'pocket': 0, 'calling': 171, 'swing': 0, 'handheld': 0}
Outliers eliminati       {'armhand': 0, 'pocket': 0, 'calling': 64, 'swing': 0, 'handheld': 0}

PDR_Raw_2019-03-29-08-30-54 {'armhand': 0, 'pocket': 157, 'calling': 0, 'swing': 0, 'handheld': 0}
Outliers eliminati       {'armhand': 0, 'pocket': 116, 'calling': 0, 'swing': 0, 'handheld': 0}

PDR_Raw_2019-03-30-11-29-16 {'armhand': 0, 'pocket': 0, 'calling': 0, 'swing': 0, 'handheld': 897}
Outliers eliminati       {'armhand': 0, 'pocket': 0, 'calling': 0, 'swing': 0, 'handheld': 167}

PDR_Raw_2019-03-31-01-23-59 {'armhand': 0, 'pocket': 0, 'calling': 0, 'swing': 0, 'handheld': 1726}
Outliers eliminati       {'armhand': 0, 'pocket': 0, 'calling': 0, 'swing': 0, 'handheld': 202}

PDR_Raw_2019-03-31-10-04-54 {'armhand': 0, 'pocket': 0, 'calling': 0, 'swing': 385, 'handheld': 0}
Outliers eliminati       {'armhand': 0, 'pocket': 0, 'calling': 0, 'swing': 156, 'handheld': 0}

PDR_Raw_2019-03-31-10-33-25 {'armhand': 0, 'pocket': 386, 'calling': 0, 'swing': 3, 'handheld': 0}
Outliers eliminati       {'armhand': 0, 'pocket': 45, 'calling': 36, 'swing': 2, 'handheld': 0}

PDR_Raw_2019-03-31-12-03-05 {'armhand': 0, 'pocket': 0, 'calling': 0, 'swing': 232, 'handheld': 0}
Outliers eliminati       {'armhand': 0, 'pocket': 0, 'calling': 0, 'swing': 21, 'handheld': 0}

PDR_Raw_2019-03-31-12-29-51 {'armhand': 0, 'pocket': 0, 'calling': 0, 'swing': 0, 'handheld': 568}
Outliers eliminati       {'armhand': 0, 'pocket': 0, 'calling': 0, 'swing': 0, 'handheld': 205}

PDR_Raw_2019-04-01-10-45-07 {'armhand': 0, 'pocket': 0, 'calling': 0, 'swing': 0, 'handheld': 1214}
Outliers eliminati       {'armhand': 0, 'pocket': 0, 'calling': 0, 'swing': 0, 'handheld': 29}

PDR_Raw_2019-04-02-08-44-50 {'armhand': 0, 'pocket': 0, 'calling': 0, 'swing': 0, 'handheld': 664}
Outliers eliminati       {'armhand': 0, 'pocket': 0, 'calling': 0, 'swing': 0, 'handheld': 60}


In totale=> armhand:723, pocket:685, calling:764, swing:1385, handheld:5827, -->9384 stride
```

In [3]:
```
stop_list["pocket"].insert(1,100)
print(stop_list)
```

```
{'armhand': [0, 196, 723], 'pocket': [0, 100, 142, 299, 685], 'calling': [0, 284, 318, 593, 764], 'swing': [0,
197, 336, 765, 1150, 1153, 1385], 'handheld': [0, 288, 333, 758, 1655, 3381, 3949, 5163, 5827]}
```

In [4]:
```
#select only one mode
mode="pocket"
for c in classi:
    if c!=mode:
        del DATASET[c]
        del stop_list[c]
```

"DATASET" è la variabile in cui importiamo il nostro dataset WDE, è un dizionario che ha come chiavi le cinque modalità, come valori ha una lista. La lista è una lista di stride, dove ogni stride è un dizionario che rappresenta le misrazioni dello stride

In [5]:
```
print(type(DATASET))
for c,v in DATASET.items():
    print(c,type(v),len(v),type(v[0]),v[0].keys())
```

```
<class 'dict'>
pocket <class 'list'> 685 <class 'dict'> dict_keys(['target', 'Acc_X', 'Acc_Y', 'Acc_Z', 'Gyr_X', 'Gyr_Y', 'Gyr
_Z', 'SensorTimestamp'])
```

Applichiamo il butterworth filter di primo ordine con cutoff frequency di 3Hz ad ogni stride

In [6]:
```
filtWDE(DATASET):
```

```
Filtering:##
Done!
```

"Feature_DS" è un dizionario con chiavi le classi, e valori dizionari con chiavi 'feature' che contiene la list di feature dello stride e 'target' che contiene il float della lunghezza dello stride.

In [7]:
```
Feature_DS=f_ext_WDE(DATASET)
```

```
Extracting pocket:#########
```

In [8]:
```
for k,v in Feature_DS.items():
    print("\n",k,type(v),v.keys(),len(v['feature']),end=" ")
    if k==mode:
        print(len(v['feature'][0]),len(v['target']))
```

```
 armhand <class 'dict'> dict_keys(['feature', 'target']) 0
 pocket <class 'dict'> dict_keys(['feature', 'target']) 685 92 685

 calling <class 'dict'> dict_keys(['feature', 'target']) 0
 swing <class 'dict'> dict_keys(['feature', 'target']) 0
 handheld <class 'dict'> dict_keys(['feature', 'target']) 0
```

- **DS_train** è il dataset equilibrato di train prendendo i primi 500 elementi per ogni modalità
- **DS_test** è il dataset di test equilibrato prendendo gli *ultimi* 50 elementi per ogni modalità

In [9]:
```
#nt=int(len(Feature_DS[mode]['target'])/10)
DS_train,DS_test = trueeqWDE(Feature_DS,stop_list,n_train=400,n_test=40)
```

In [10]:
```
for k,v in DS_train.items():
    print("\n",k,type(v),v.keys(),len(v['feature']),end=" ")
    if k==mode:
        print(len(v['feature'][0]),len(v['target']))
```

```
 armhand <class 'dict'> dict_keys(['feature', 'target']) 0
 pocket <class 'dict'> dict_keys(['feature', 'target']) 400 92 400

 calling <class 'dict'> dict_keys(['feature', 'target']) 0
 swing <class 'dict'> dict_keys(['feature', 'target']) 0
 handheld <class 'dict'> dict_keys(['feature', 'target']) 0
```

In [11]:
```
for k,v in DS_test.items():
    print("\n",k,type(v),v.keys(),len(v['feature']),end=" ")
    if k==mode:
        print(len(v['feature'][0]),len(v['target']))
```

```
 armhand <class 'dict'> dict_keys(['feature', 'target']) 0
 pocket <class 'dict'> dict_keys(['feature', 'target']) 40 92 40

 calling <class 'dict'> dict_keys(['feature', 'target']) 0
 swing <class 'dict'> dict_keys(['feature', 'target']) 0
 handheld <class 'dict'> dict_keys(['feature', 'target']) 0
```

- **regr_dataset_train** è il dataset formattato per la regressione per il train, non tiene in considerazione le modalità ed unisce tutte le feature in una lista e così tutti i target. E' un dizionario con chiavi 'feature' e 'target'
- **regr_dataset_test** è lo stesso, ma con i dati di test

In [12]:
```
regr_dataset_train, regr_dataset_test = full_regr_dataset(DS_train,DS_test)
```

In [13]:
```
for k,v in regr_dataset_train.items():
    print(k,type(v),len(v),type(v[0]))
```

```
feature <class 'list'> 400 <class 'list'>
target <class 'list'> 400 <class 'float'>
```

In [14]:
```
for k,v in regr_dataset_test.items():
    print(k,type(v),len(v),type(v[0]))
```

```
feature <class 'list'> 40 <class 'list'>
target <class 'list'> 40 <class 'float'>
```

Isoliamo i singoli **F_x,F_y** rispettivamete feature e target del train e **F_x_test,F_y_test** rispettivamente feature e target di test

In [15]:
```
F_x=np.array(regr_dataset_train["feature"])
F_y=np.array(regr_dataset_train["target"])
F_x_test=np.array(regr_dataset_test["feature"])
F_y_test=np.array(regr_dataset_test["target"])
```

Vediamo come sono distibuite le lunghezze registrate degli stride

In [16]:
```
#istogramma dei target F_y
ist_stride_lenght(F_y)
```

```
Registered Stride lenght: Min:  1.0751676431373292 , Max:  1.5636839646424296
Media= 1.3980466542256742; Deviazione standard= 0.08532546344501384.
```

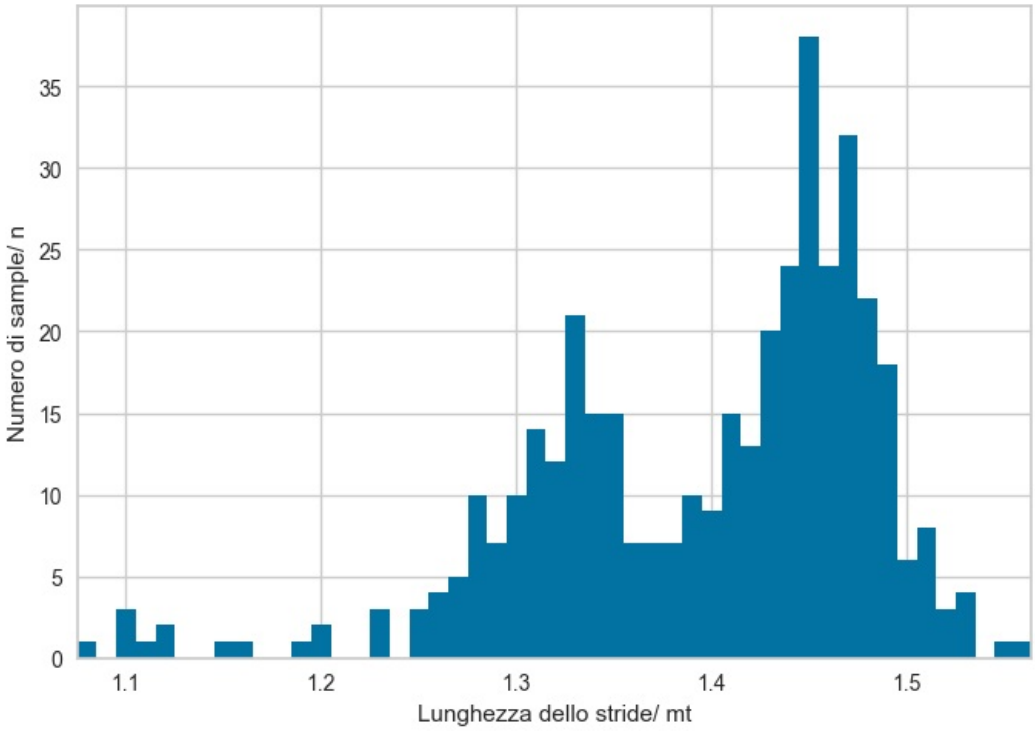

Out[16]: 0

In [17]:
```
#istogramma dei target di test
ist_stride_lenght(F_y_test)
```

```
Registered Stride lenght: Min:  1.1284244664365115 , Max:  1.3661516191079124
Media= 1.3059391316311306; Deviazione standard= 0.051574859481648826.
```

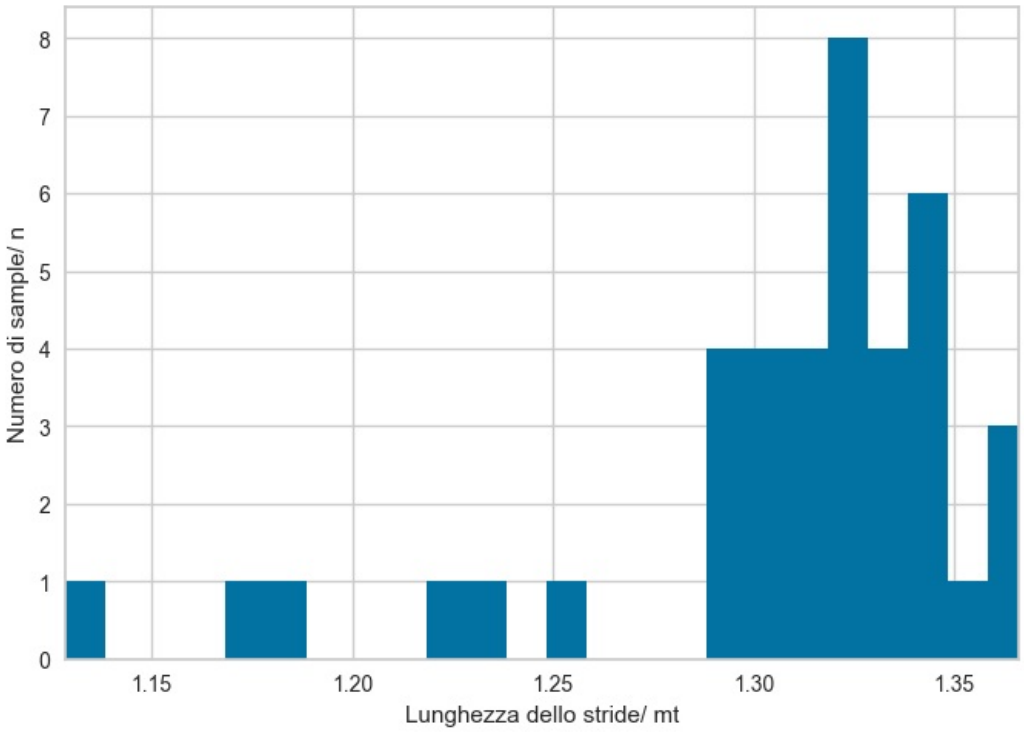

Out[17]: 0

----------Feature Analysis----------

Salviamo la lista dei nomi delle feature.

In [18]:
```
feature_name=['Acc_X-mean', 'Acc_X-std', 'Acc_X-ske', 'Acc_X-kurt', 'Acc_X-iqr', 'Acc_X-Ma', 'Acc_X-zc', 'Acc_X
print(f"Abbiamo: {len(feature_name)} feature.")
```

```
Abbiamo: 92 feature.
```

rank1d e rank2d offrono la possibilità di visualizzare in modo semplice ed intuitivo il ranking delle feature. In particolare:

- **rank1d** utilizza shapiro da scipy.stats per calcolare lo score di ogni feature e poi plotta lo score in un barchart di matplotlib.
- **rank2d** valuta lo score per ogni coppia di feature, le funzioni di scoring supportate sono <"pearson","covariance","spearman","kendalltau"> che misurano quanto le feature sono legate tra di loro; noi utilizziamo "pearson".

In [19]:
```
#rank1d
_, axes = plt.subplots(ncols=1, figsize=(16,16))
rank1d(F_x,F_y,features=feature_name,ax=axes , show=False)
plt.show()
```

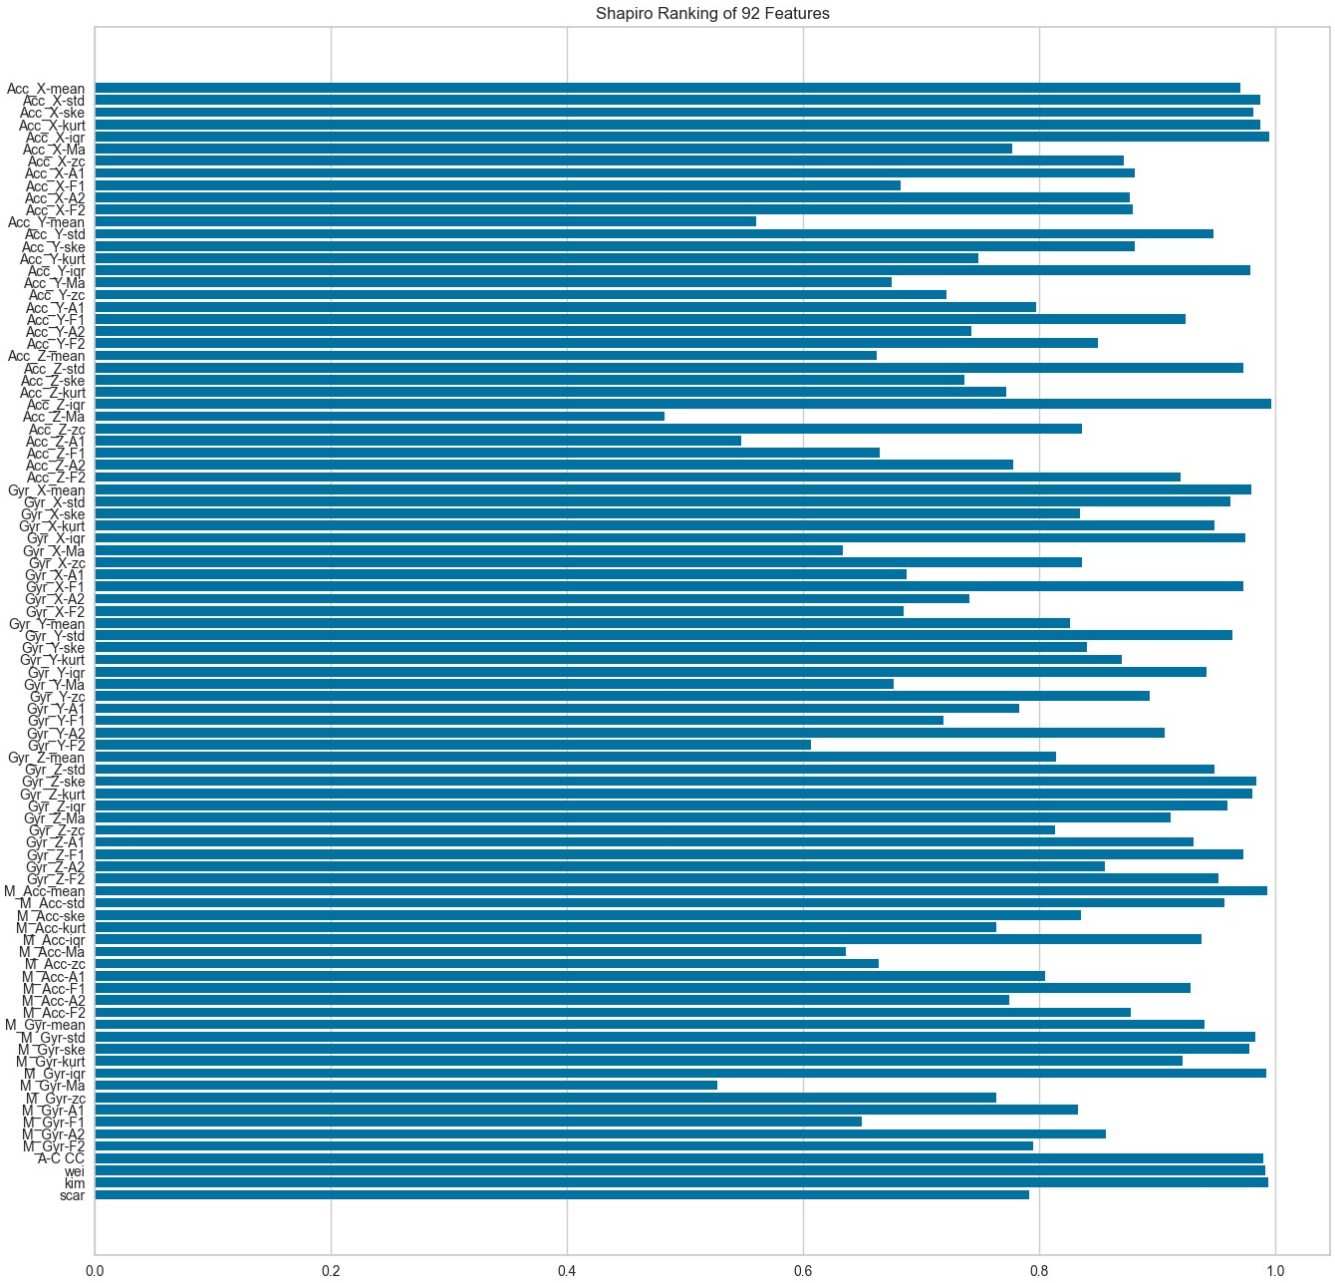

In [20]:
```
####rank2d

##Per visualizzare cosa sceglierà f_regression
#devo fare in modo che tra le feature ci sia anche il target #poi vedere solo la linea riferita al target e ved

HP_x=np.hstack((F_x,np.reshape(F_y,(-1,1))))

HP_featurename=feature_name+["TARGET"]

_, axes = plt.subplots(ncols=1, figsize=(16,16))

rank2d(HP_x,features=HP_featurename,ax=axes , show=False)

plt.show()

#Si vede sia ogni coppia di feature come è relazionata, sia il pearson score con il target di ogni feature!
```

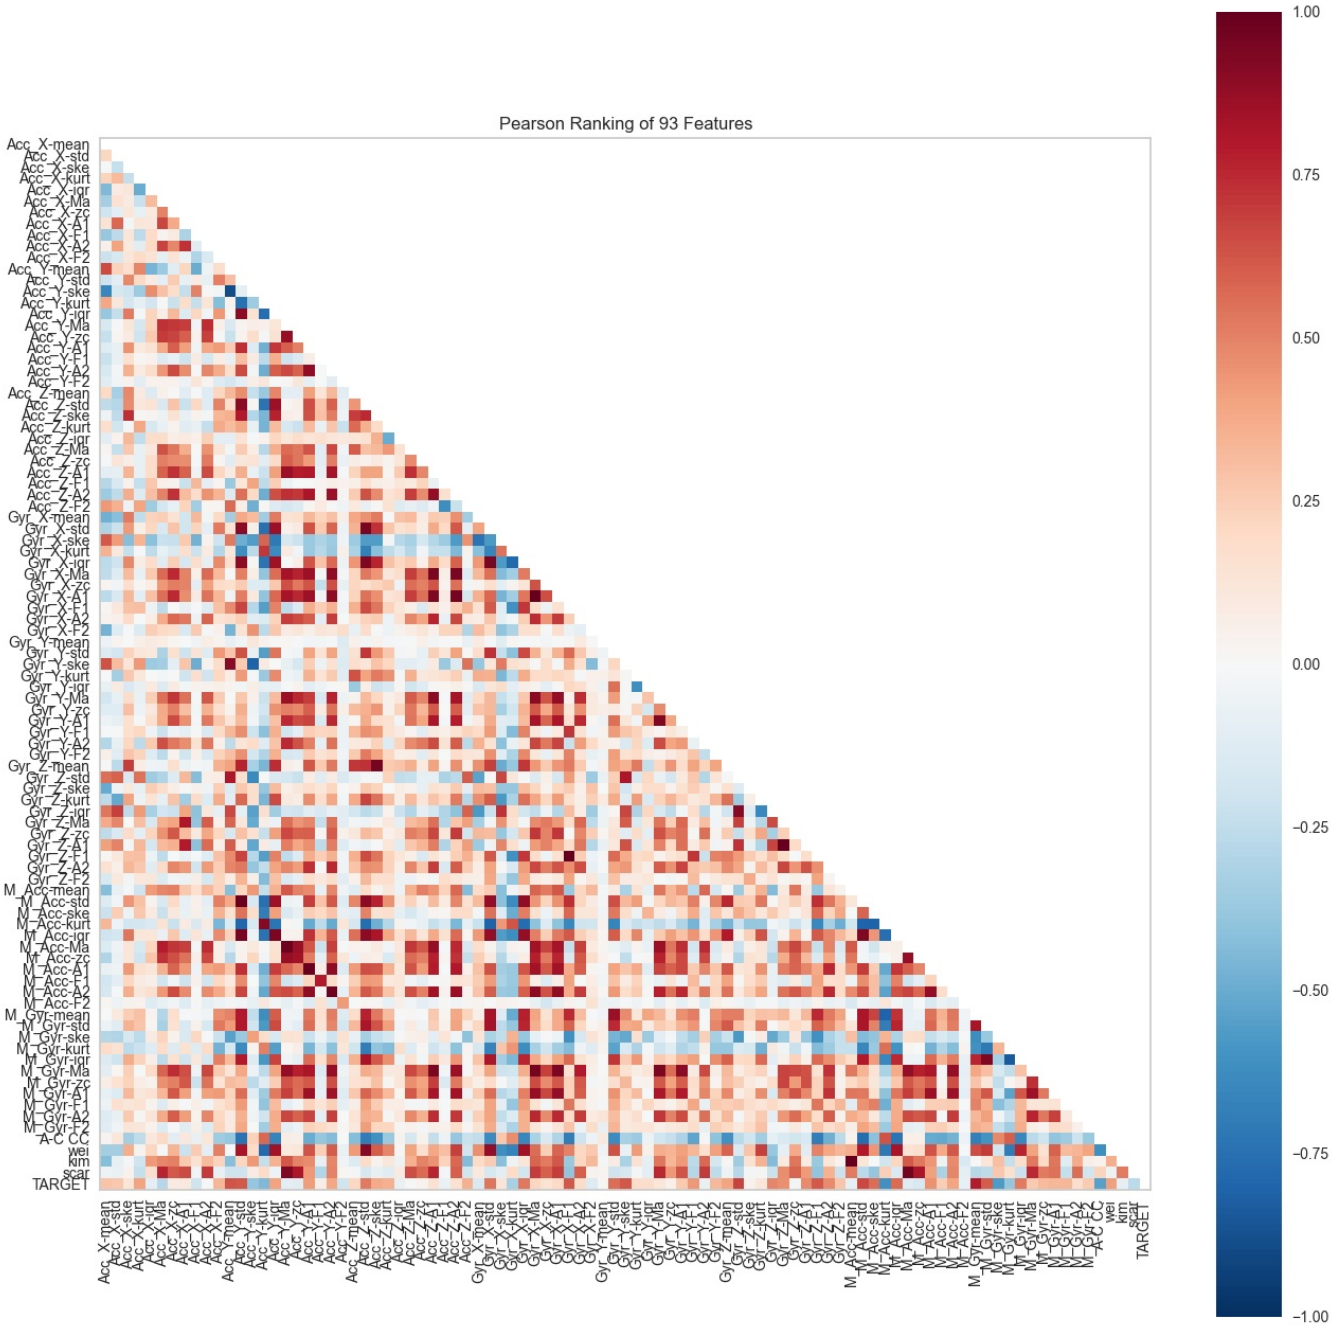

Linear Regression

Descrizione:

- **input** : F_x ed F_y che sono rispettivamente il vettore di vettori di feature ed il vettore di target.
- **perf** è un oggetto scorer costruito dalla funzione che noi desideriamo usare comemetro di valutazione per le performance, nel nostro caso error_rate.
- **kf** è l'oggetto che crea gli indici per dividere i nostri input in k (10) fold da usare per la cross validation.
- **pipe** è l'oggetto che rappresenta la pipeline degli estimatori, ogni step fa il fit con il predict del precedente; in ordine l'input viene ridotto selezionando le feature (SelectKbest con f_regression)-> le feature vengono scalate (StandardScaler)-> il modello lineare viene fittato (LinearRegression) f_regression usa come metodo di ranking il pearson tra la singola feature ed il target.
- **est** è l'istanza GridSearchCV che permette di eseguire la cross validation tramite gli indici di kf (facendo quindi in tutto k (10) train usando ogni volta un fold diverso per il test) e di volta in volta testa una nuova combinazione di parametri presenti nel dizionario param (nel nostro caso solo quante feature selezionare, da 1 a 92). Per ogni parametro esegue una 10-fold cross-validation e calcola la media dello score calcolato con perf. Infine restituisce come .best_params_ i parametri con cui si ha avuto la migliore media, con .best_estimator_ restituisce un estimatore fittato su tutti i dati di train con il best_param_.

Salvo quindi il miglior estimatore in best che rappresenta quindi l'estimatore che ha il minor error_rate medio nei k fold con i migliori parametri, fittato su tutto il set di dati di train senza la divisione in fold.

In [21]:
```
#F_x feature #F_y target

#Creiamo l'oggetto per valutare le performance tramite la nostra funzione
perf=make_scorer(error_rate, greater_is_better=False)
```

```
#Creiamo oggetto cross-validator tramite KFold
kf = KFold(n_splits=10, shuffle= True, random_state=0)#con lo shuffle= False assicuriamo che i blocchi siano co

##############GRIDSEARCH_CV
#select = SelectKBest(score_func=f_regression)
#scaler=StandardScaler()
#regr = linear_model.LinearRegression()

#pipeline di estimatori
pipe = Pipeline([('select',SelectKBest(score_func=f_regression)),('scaler', StandardScaler()), ('regr', linear_
print("La pipeline è composta da: ", pipe)

#Parametri da testare:
param=[{'select__k':[x+1 for x in range(F_x.shape[1])]}]

#Creiamo l'oggetto per la ricerca dei parametri
est=GridSearchCV(pipe,param_grid= param, cv=kf,verbose=1,scoring="r2", return_train_score= True) #Fittiamo sul
est.fit(F_x,F_y)

#Ricaviamo il miglior set di parametri
best=est.best_estimator_
print(f"\n\nIl miglior estimatore si ha col parametro {est.best_params_} ottenuto all'indice: {est.best_index_}
```

```
La pipeline è composta da:  Pipeline(steps=[('select',
                 SelectKBest(score_func=<function f_regression at 0x0000016B75C6A8C0>)),
                ('scaler', StandardScaler()), ('regr', LinearRegression())])
Fitting 10 folds for each of 92 candidates, totalling 920 fits


Il miglior estimatore si ha col parametro {'select__k': 22} ottenuto all'indice: 21 .

 L'R2-score medio è di 0.753 !
```

-----MODEL EVALUETION-----

LearningCurve permette di vedere l'evoluzione delle performance del modello facendo la media dello score nella cross validation (asse y) in base al numero di train samples (asse x). Permette di valutare:

- Se il modello necessita di maggiori dati di training (se convege vuol dire che aumentare il numero di sample migliora le performance, se converge in un valore troppo alto vuol dire che necessita più sample in training)
- Se l'errore dipende di più dalla media o dalla varianza

In [22]:
```
viz = LearningCurve(best, scoring="r2",cv=kf,train_sizes=np.linspace(0.8,1.0,5))

viz.fit(F_x,F_y) # Fit the data to the visualizer
viz.show()
```

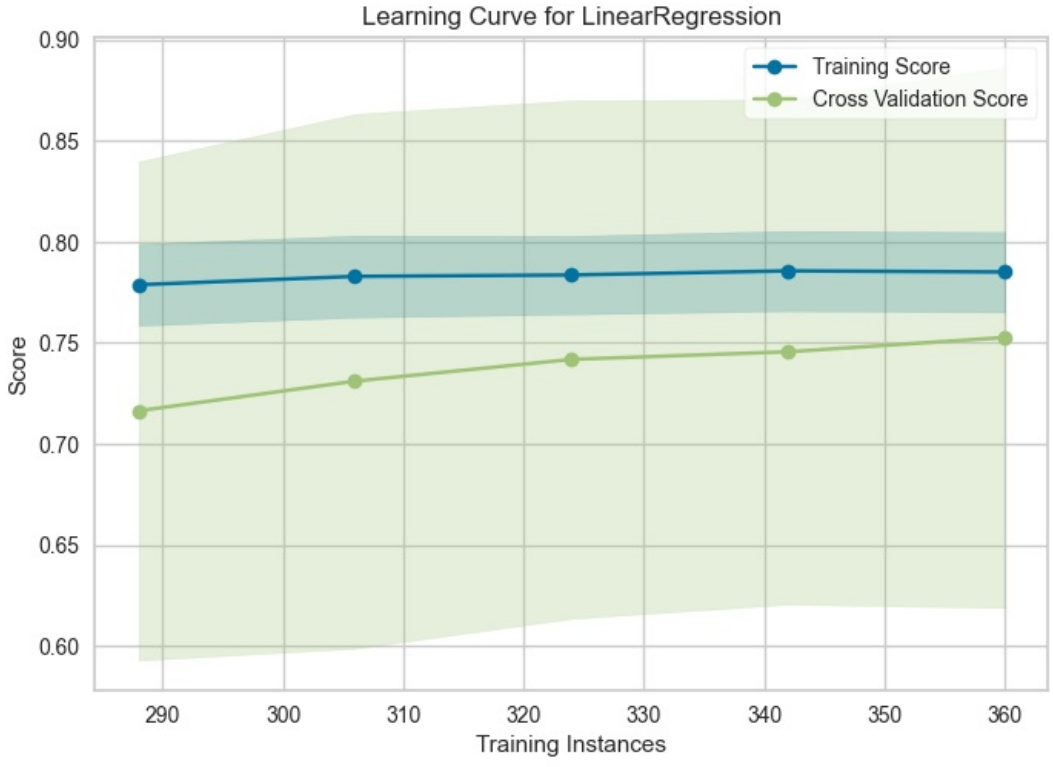

Out[22]:
```
<AxesSubplot:title={'center':'Learning Curve for LinearRegression'}, xlabel='Training Instances', ylabel='Score
'>
```

-----FEATURE IMPORTANCE-----

FeatureImportances permette di plottare le feature del best estimator ordinate in ordine decrescente secondo la loro importanza!

In [23]:
```
#per la feature importance dobbiamo scomporre la pipeline, ci serve solo l'ultimo step, il regressore nominato
##Attenzione FeatureImportance.fit trasforma il regressore, quindi creiamone uno nuovo
kk=est.best_params_['select__k']
skb=SelectKBest(score_func=f_regression, k=kk)
temp_X=skb.fit_transform(F_x,F_y)
stdsc=StandardScaler()
temp_X=stdsc.fit_transform(temp_X)
linmod=linear_model.LinearRegression()

_, axes = plt.subplots(ncols=1, figsize=(16,16))
viz = FeatureImportances(linmod,ax=axes,labels=feature_name)
viz.fit(temp_X,F_y)
viz.show()
```

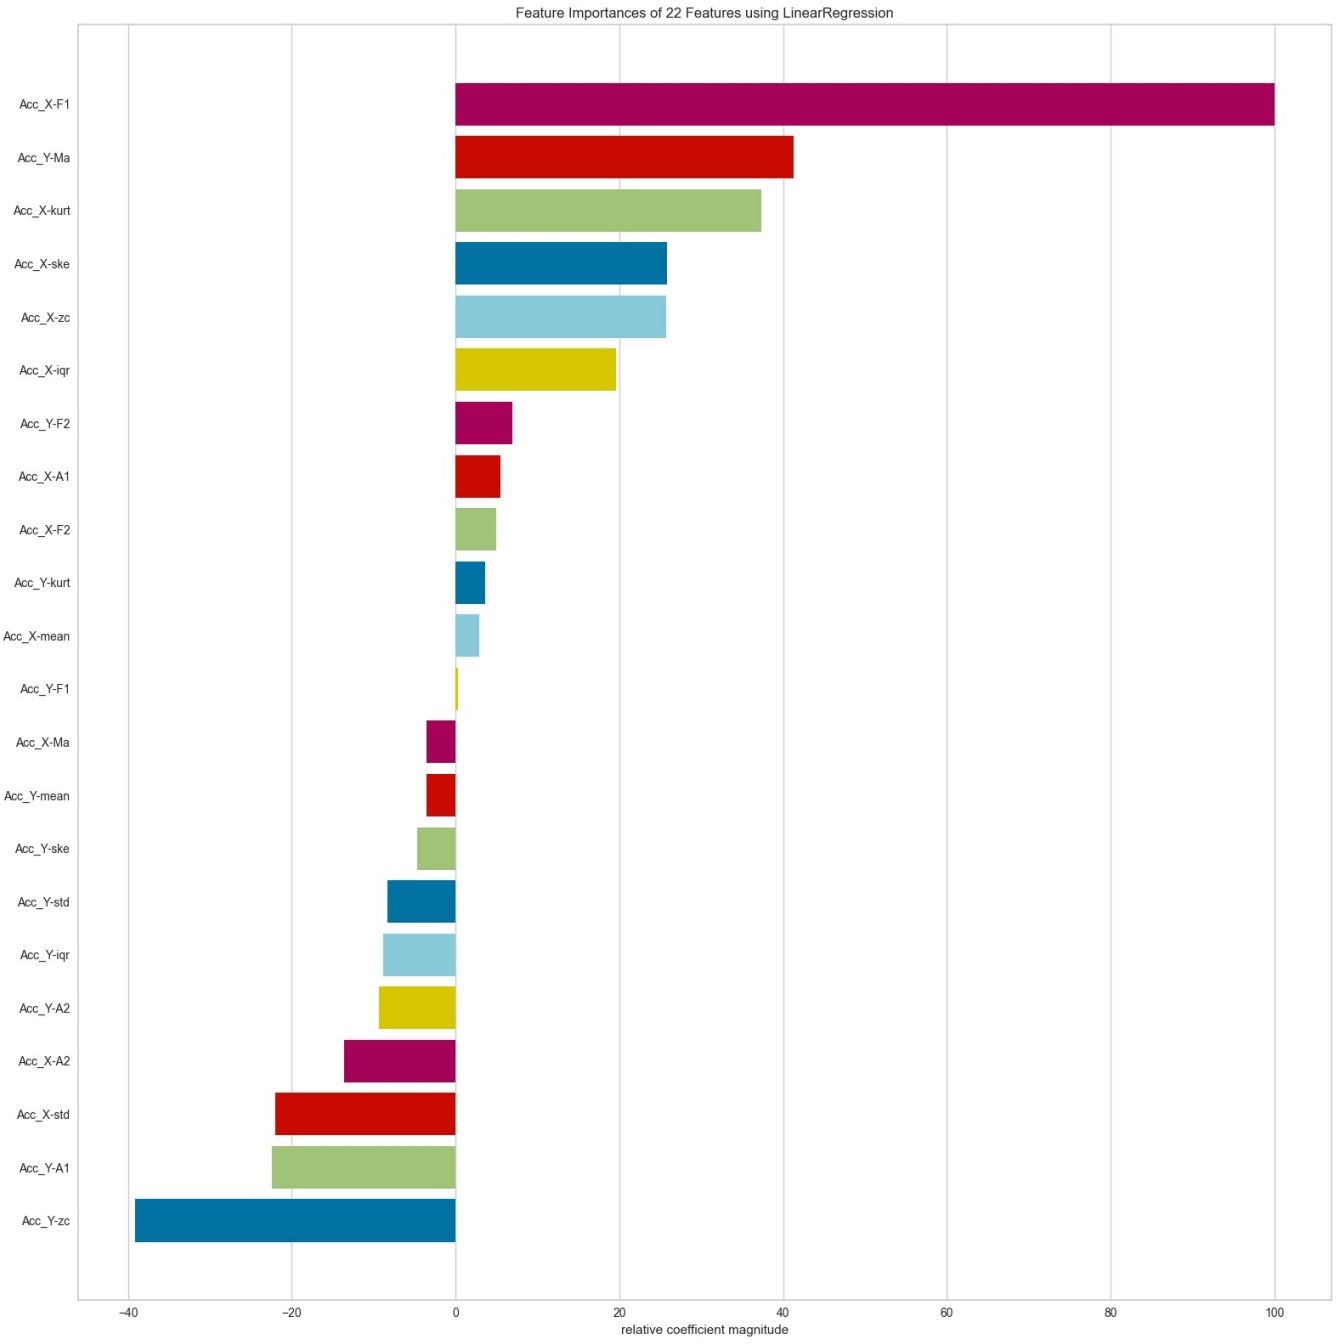

Out[23]:
```
<AxesSubplot:title={'center':'Feature Importances of 22 Features using LinearRegression'}, xlabel='relative coe
fficient magnitude'>
```

Visualizziamo tutti i risultati del GridSearchCV

Qui possiamo vedere ogni split con ogni parametro che score ha ottenuto, sia per il train (9 fold) che per il test (1 fold). Es: split3 è la cross validation usando come train fold (0..2,4..10) e come test fold 3 .

Le righe corrispondono alle performance dell'estimatore con un determinato parametro (92 righe come il numero di parametri testati); le colonne rappresentano gli il determinato score per ogni parametro.

In [24]:
```
risultati=pd.DataFrame(est.cv_results_)
display(risultati)
```

	mean_fit_time	std_fit_time	mean_score_time	std_score_time	param_select__k	params	split0_test_score	split1_test_score	split2_tes
0	0.002400	0.003665	0.000800	0.002400	1	{'select__k': 1}	0.702136	0.693187	0.
1	0.003613	0.003661	0.000000	0.000000	2	{'select__k': 2}	0.815672	0.701038	0.
2	0.003701	0.003838	0.001664	0.003332	3	{'select__k': 3}	0.845166	0.848938	0.
3	0.004270	0.003499	0.001214	0.003013	4	{'select__k': 4}	0.845602	0.842278	0.
4	0.002402	0.003669	0.001562	0.004687	5	{'select__k': 5}	0.853076	0.818043	0.
...	...	...	...	...	...	...	...	...	
87	0.025329	0.006494	0.001562	0.004686	88	{'select__k': 88}	0.779793	-1.605991	0.
88	0.030080	0.003833	0.000000	0.000000	89	{'select__k': 89}	0.780591	-0.125665	0.
89	0.030003	0.003977	0.000000	0.000000	90	{'select__k': 90}	0.771491	0.153661	0.
90	0.025887	0.006593	0.000000	0.000000	91	{'select__k': 91}	0.815226	0.645514	0.
91	0.032370	0.002646	0.000000	0.000000	92	{'select__k': 92}	0.820074	0.345557	0.

92 rows × 31 columns

Selezioniamo solo i dati relativi all'errore negli split di train e test Per poter costruire i seguenti boxplot.

In [25]:
```
#lable di tutte le colonne
column_names=list(risultati)
#lable di ciò che non ci interessa nei nuovi dataframe
column_names=[x for x in column_names if x[0:5]!="split"]
#creiamo un nuovo dataframe eliminando queste colonne
data=risultati.drop(column_names,axis=1)

#creiamo due nuovi dataframe con solo split test e split train
column_names=list(data)
data_train=data.drop(column_names[:int(len(column_names)/2)],axis = 1)
data_test=data.drop(column_names[int(len(column_names)/2):],axis = 1)
display(data_train.iloc[[0,1, -1]])
display(data_test.iloc[[0,1, -1]])
```

	split0_train_score	split1_train_score	split2_train_score	split3_train_score	split4_train_score	split5_train_score	split6_train_score	split7_t
0	0.606310	0.590739	0.616571	0.607201	0.612780	0.628150	0.641499	
1	0.707819	0.591109	0.619223	0.708076	0.716269	0.629464	0.745941	
91	0.878580	0.874714	0.881108	0.881699	0.889332	0.878750	0.917762	

	split0_test_score	split1_test_score	split2_test_score	split3_test_score	split4_test_score	split5_test_score	split6_test_score	split7_test_s
0	0.702136	0.693187	0.555681	0.659164	0.619155	0.497910	0.456544	0.603
1	0.815672	0.701038	0.526059	0.772100	0.713700	0.499293	0.544740	0.699
91	0.820074	0.345557	0.737875	0.729973	0.711512	0.795229	0.348085	0.832

Plottiamo le performance al variare del parametro k Nell'asse x il numero di feature selezionate, nell'asse y il relativo error_rate per il nostro dataset.

In [26]:
```
#plot train
boxdata=data_train.values
flierprops = dict(marker='.',markeredgecolor='firebrick', markersize=3, linestyle='none')
medianprops = dict(linestyle='-', linewidth=1.75, color='green')
meanprops = dict(linestyle='-',linewidth=2,color='r')

bp=plt.boxplot(boxdata.tolist(), flierprops=flierprops, medianprops=medianprops, showmeans= True, meanline = Tr
plt.xticks([x for x in range(1,len(risultati["mean_train_score"])+1) if x%5==0],[str(x) for x in param[0]["sele
plt.xlabel("Selected top k feature / n",fontsize=15)
plt.ylabel("R2-score",fontsize=15)
plt.grid(True)
plt.legend([bp['medians'][0], bp['means'][0]], ['Median', 'Mean'], fontsize='x-large')
plt.title("Mean TRAIN R2-Score al variare del numero di feature",fontsize=20)
plt.show()
```

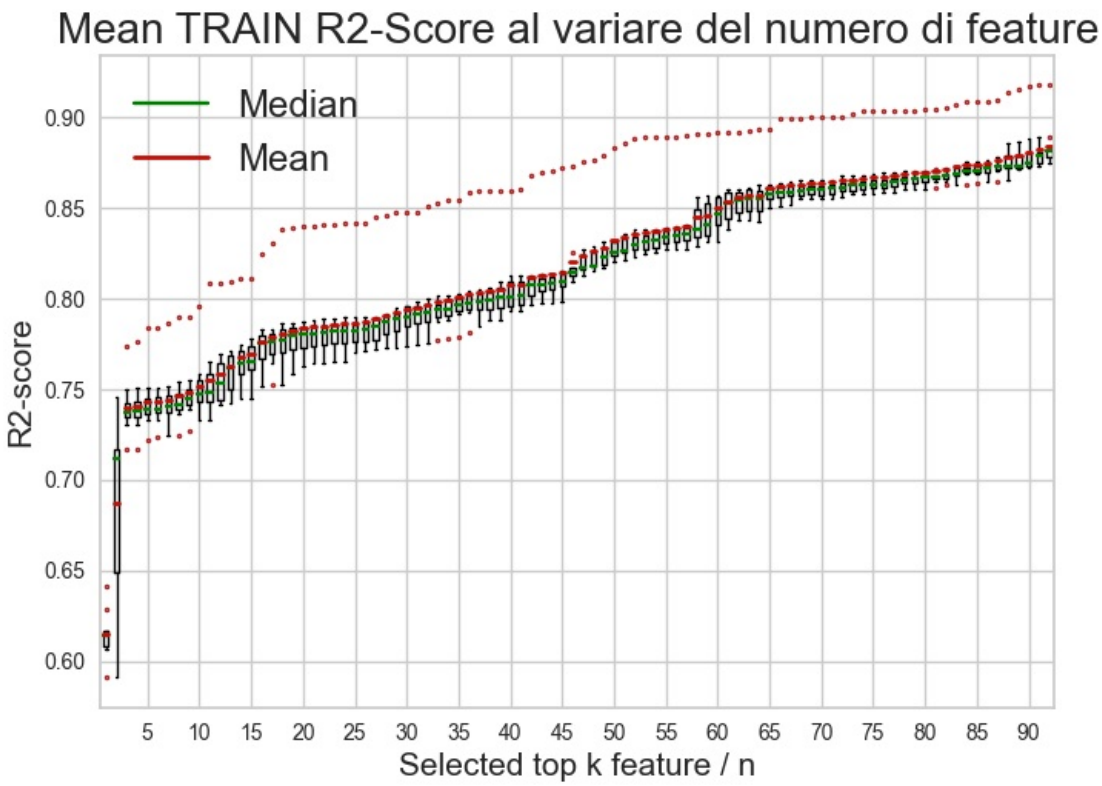

In [27]:
```
#plot test
boxdata=data_test.values
flierprops = dict(marker='.',markeredgecolor='firebrick', markersize=3, linestyle='none')
medianprops = dict(linestyle='-', linewidth=1.75, color='green')
meanprops = dict(linestyle='-',linewidth=2,color='r')

bp=plt.boxplot(boxdata.tolist(), flierprops=flierprops, medianprops=medianprops, showmeans= True, meanline = Tr
plt.xticks([x for x in range(1,len(risultati["mean_test_score"])+1) if x%5==0],[str(x) for x in param[0]["selec
plt.xlabel("Selected top k feature / n",fontsize=15)
plt.ylabel("R2-Score",fontsize=15)
plt.grid(True)
plt.legend([bp['medians'][0], bp['means'][0]], ['Median', 'Mean'], fontsize='x-large')
plt.title("Mean TEST R2-Score al variare del numero di feature",fontsize=20)
plt.show()
```

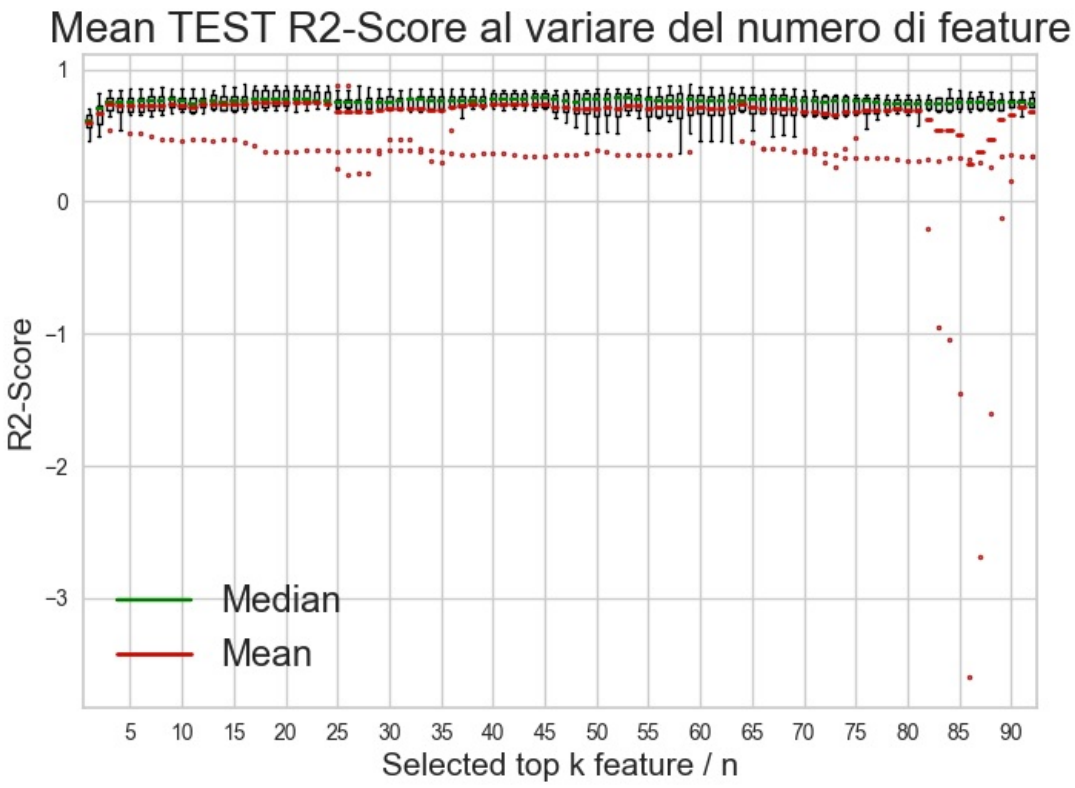

Alla luce dei seguenti dati potrebbe essere conveniente non utilizzare il miglior estimatore, in quel caso basterebbe creare una pipeline allo stesso modo, utilizzando come parametro il parametro desiderato, senza l'utilizzo di GridSearchCV

Es (k=20):

best = Pipeline([('select',SelectKBest(score_func=f_regression,k=20)),('scaler', StandardScaler()), ('regr', linear_model.LinearRegression())])

Calcoliamo Akaike Information Criterion (**AIC**) per il modello con featre da 1-92 e vediamo il contenuto informativo

In [28]:
```
import statsmodels.api as sm

AICs=[]
print("Fitting model:",end=" ")
for sk in [x+1 for x in range(92)]:

    print(f"{sk}.",end="")
    SKB=SelectKBest(score_func=f_regression, k=sk)
    t_X=SKB.fit_transform(F_x,F_y)
    SSC=StandardScaler()
    t_X=SSC.fit_transform(t_X)

    #fit regression model
    m_a = sm.OLS(F_y, t_X).fit()

    AICs.append(m_a.aic)
```

```
Fitting model: 1.2.3.4.5.6.7.8.9.10.11.12.13.14.15.16.17.18.19.20.21.22.23.24.25.26.27.28.29.30.31.32.33.34.35.
36.37.38.39.40.41.42.43.44.45.46.47.48.49.50.51.52.53.54.55.56.57.58.59.60.61.62.63.64.65.66.67.68.69.70.71.72.
73.74.75.76.77.78.79.80.81.82.83.84.85.86.87.88.89.90.91.92.
```

__Plottiamo__

In [29]:
```
plt.plot([x+1 for x in range(92)],AICs)
plt.xticks([x for x in range(92) if x%5==0])
plt.grid(True)
plt.show()
print(np.array(AICs))
```

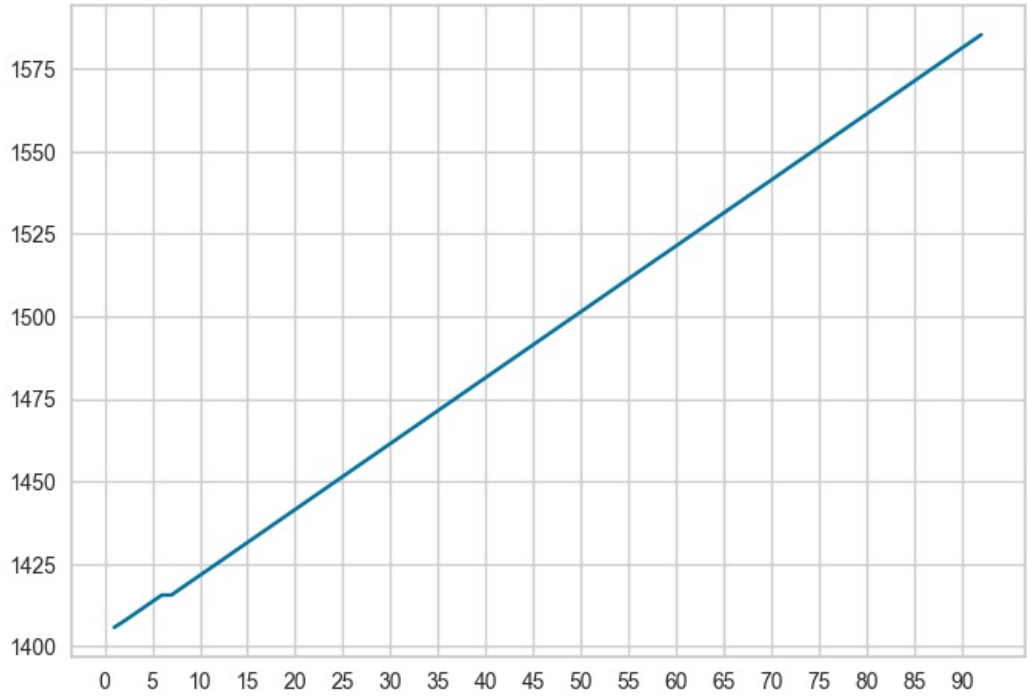


```
[1405.78573909 1407.63382063 1409.59952213 1411.59942339 1413.59554874
 1415.59420354 1415.59420354 1417.59412332 1419.58851381 1421.58323942
 1423.56329789 1425.56305548 1427.56280323 1429.56176228 1431.55921049
 1433.54575062 1435.54302113 1437.54271582 1439.53771299 1441.53723245
 1443.53553973 1445.53498083 1447.53482715 1449.5343989  1451.5343937
 1453.53333752 1455.53251247 1457.52709016 1459.52344124 1461.52259601
 1463.52199817 1465.52188136 1467.5169734  1469.51441153 1471.51038875
 1473.50995838 1475.50994568 1477.50964153 1479.50745465 1481.50745421
 1483.49690882 1485.49595193 1487.49593449 1489.49559959 1491.48380586
 1493.48066905 1495.47904385 1497.47833036 1499.47790712 1501.46950937
 1503.46670697 1505.46483094 1507.46387762 1509.46376851 1511.46328998
 1513.46316791 1515.46268469 1517.45952573 1519.43626945 1521.42954266
 1523.42739017 1525.42595886 1527.42567065 1529.42561998 1531.42342892
 1533.42320952 1535.42319865 1537.42288575 1539.42178435 1541.4215518
 1543.42150716 1545.42086228 1547.42081101 1549.42077907 1551.42073004
 1553.41931419 1555.41711086 1557.41641497 1559.41452968 1561.41364071
 1563.41290693 1565.41253529 1567.41067292 1569.41066241 1571.40852694
 1573.4075317  1575.40733487 1577.40717159 1579.40419809 1581.39426193
 1583.39388322 1585.39252168]
```

Essendo il modello molto leggero il tempo di fit è sempre uguale, quindi è ovvio che avere più feature sia più informativo e quindi un AIC score migliore

++

Visualize regression with **yellowbrick**

y = true value
ŷ = predicted value
Residuals = y_pred - y_true
Purtroppo non è possibile cambiare lo scoring method della figura, quindi nella legenda comparirà R^2 invece del nostro error rate, che viene quindi calcolato separatamente.

----------------------- USE BEST PREDICTOR ON **TRAIN** DATA -----------------------

CALCOLIAMO l'error_rate medio nel train.

In [30]:
```
y_pred=best.predict(F_x)
print(f"\nErrore medio del dataset: {error_rate(F_y,y_pred):.3f}% !")
```

```
Errore medio del dataset: 1.877% !
```

In [31]:
```
#F_x feature 92 #F_y target

visualizer= PredictionError(best,bestfit=True)

#visualizer.fit(F_x, F_y) # Fit the training data in the visualizer # best is already fitted on F_x F_y!
visualizer.score(F_x, F_y)#train # Evaluate the model on data (train or test)
visualizer.show() # Finalize and render the figure ;
```

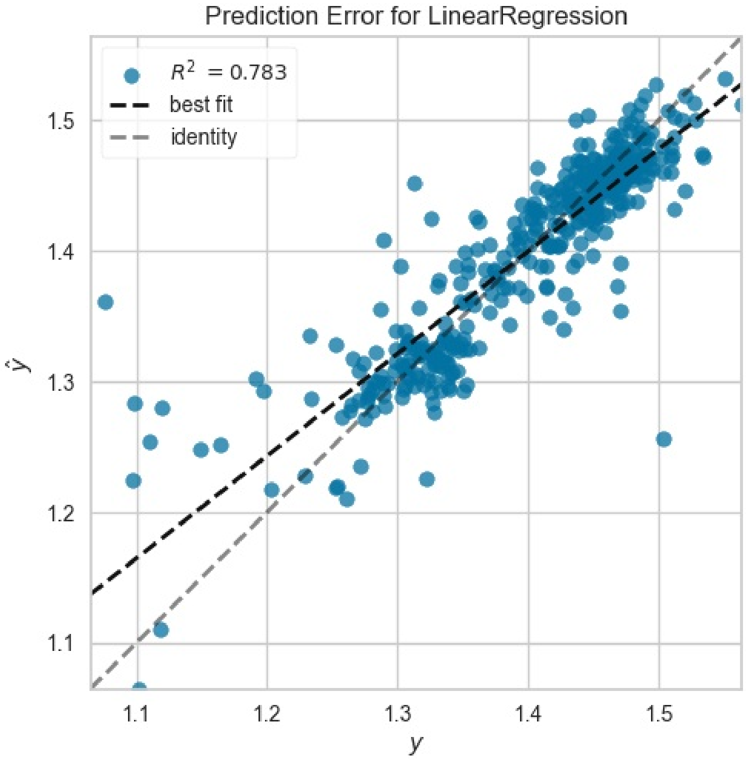

Out[31]: <AxesSubplot:title={'center':'Prediction Error for LinearRegression'}, xlabel='y', ylabel='$\\hat{y}$'>

In [32]:
```
visualizer= ResidualsPlot(best)

#visualizer.fit(F_x, F_y)# Fit the training data in the visualizer # best is alredy fitted on F_x F_y!
visualizer.score(F_x, F_y)#train # Evaluate the model on data (train or test)
visualizer.show() # Finalize and render the figure ;
#facendo il fit questo grafico restituisce anche il train, ma nel nostro caso train e test sono gli stessi, #st.
```

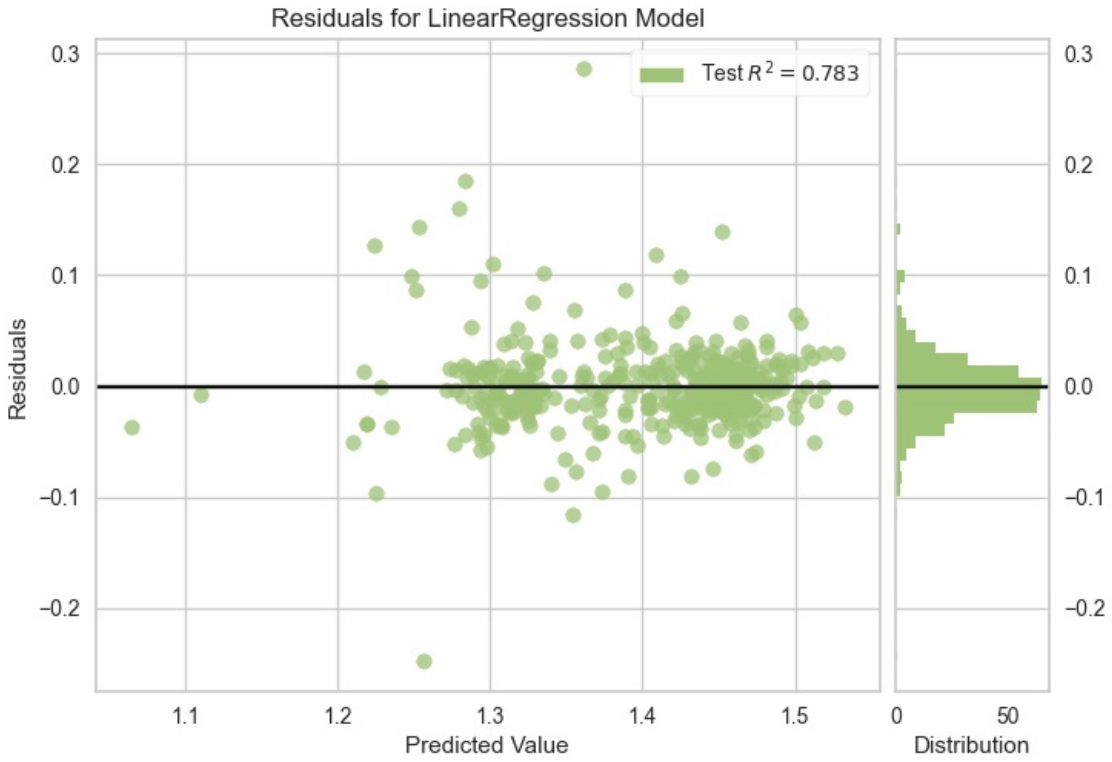

Out[32]: <AxesSubplot:title={'center':'Residuals for LinearRegression Model'}, xlabel='Predicted Value', ylabel='Residuals'>

Dall'istogramma laterale vediamo anche la distribuzione dell'errore in metri!

---------- USE BEST PREDICTOR ON **TEST** DATA ----------

In [33]:
```
#predict with best predictor
b_pred=best.predict(F_x_test)

#evaluate error_rate
print(f"Error rate: {error_rate(F_y_test,b_pred):.3f}% ")
```

```
Error rate: 2.085%
```

In [34]:
```
visualizer= PredictionError(best,bestfit=False)

#visualizer.fit(F_x, F_y) # Fit the training data in the visualizer # best is already fitted on F_x F_y!
visualizer.score(F_x_test, F_y_test)#test # Evaluate the model on data (train or test)
visualizer.show() # Finalize and render the figure
```

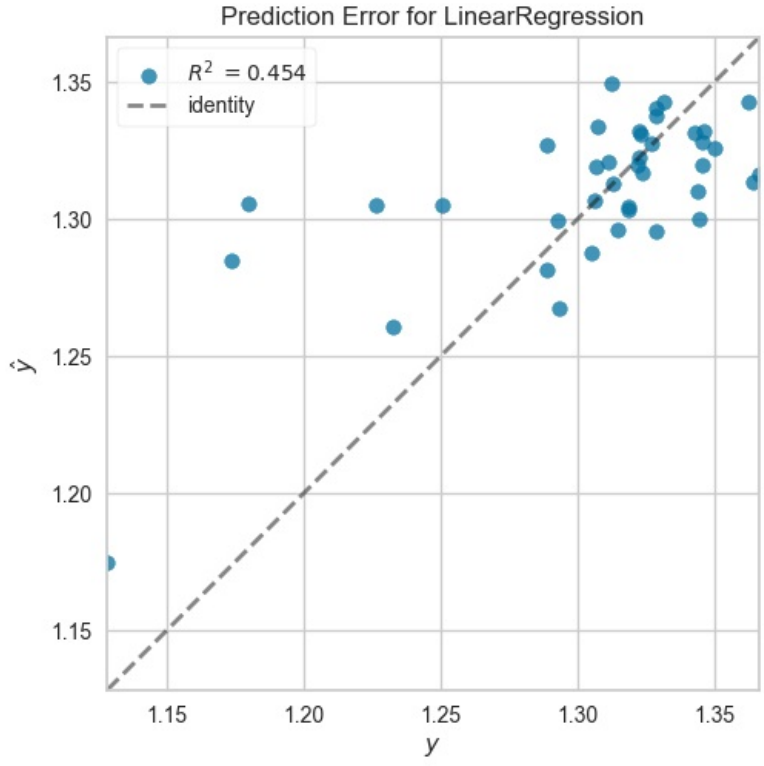

Out[34]: <AxesSubplot:title={'center':'Prediction Error for LinearRegression'}, xlabel='y', ylabel='$\\hat{y}$'>

In [35]:
```
visualizer= ResidualsPlot(best)

visualizer.fit(F_x, F_y) # Fit the training data in the visualizer # best is alredy fitted on F_x F_y!
visualizer.score(F_x_test, F_y_test)#test # Evaluate the model on data (train or test)
visualizer.show() # Finalize and render the figure
```

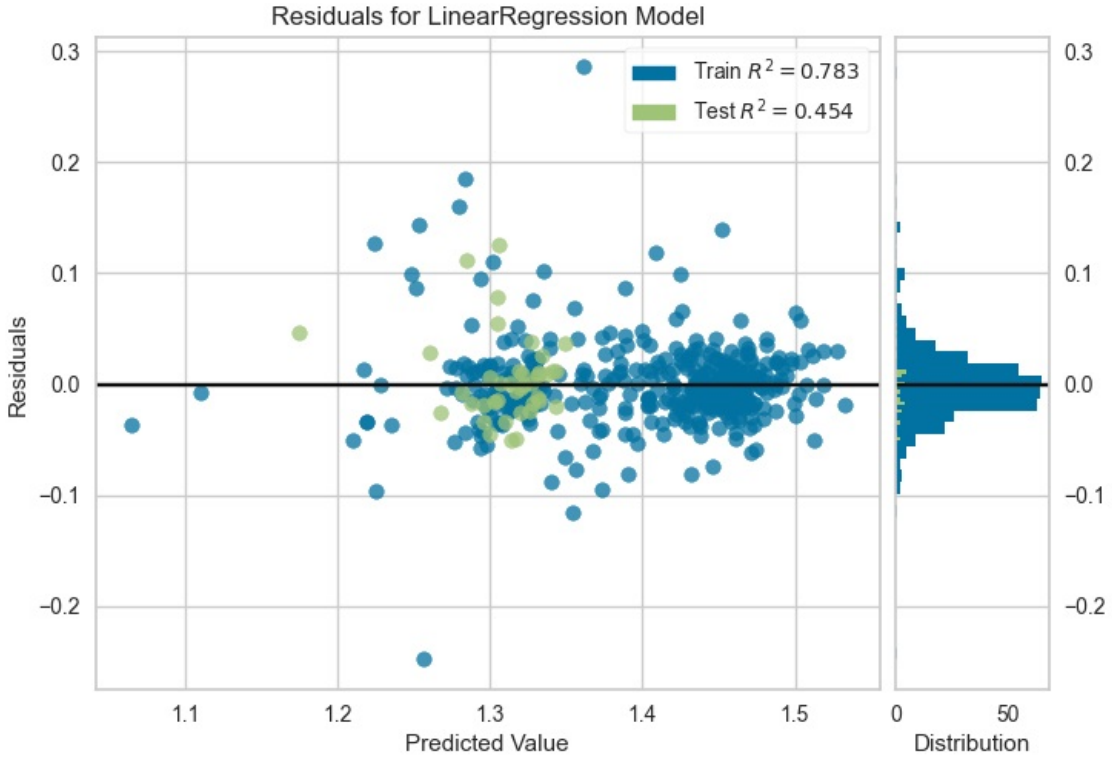

Out[35]:
```
<AxesSubplot:title={'center':'Residuals for LinearRegression Model'}, xlabel='Predicted Value', ylabel='Residua
ls'>
```

Dall'istogramma laterale vediamo anche la distribuzione dell'errore in metri!

Vediamo l'R2 score e plottiamolo sopra il boxplot che rappresenta la distribuzione dell' ERRORE IN METRI

In [36]:
```
#predict
b_pred=best.predict(F_x_test)
mt_err_dist=((b_pred-F_y_test)/F_y_test)*100
r2_scores=r2_score(F_y_test,b_pred)

flierprops = dict(marker='.',markeredgecolor='firebrick', markersize=3, linestyle='none')
medianprops = dict(linestyle='-', linewidth=1.75, color='green')
meanprops = dict(linestyle='-',linewidth=2,color='r')

bp1=plt.boxplot(mt_err_dist.tolist(), flierprops=flierprops, medianprops=medianprops, showmeans= True, meanline
plt.text(1,np.mean(mt_err_dist)+np.std(mt_err_dist),int(r2_scores*100)/100,horizontalalignment="center",color="
plt.xlabel("Modalità",fontsize=15)
plt.ylabel("Distribuzione dell'errore in percentuale /%",fontsize=15)
plt.grid(True)
plt.legend([bp1['medians'][0], bp1['means'][0]], ['Median', 'Mean'], fontsize='xx-large')
plt.title("Mean TEST Score per le 5 modalità",fontsize=25)
plt.show()
```